

Индексатор Содержания Видеолекций

Техническое Задание & План Реализации

13 марта 2025 г.

Подготовил
студент 3 курса
группы Б22-221
Сидюк Д.А.

Содержание

1	Краткое Изложение	2
2	Обзор Системы	2
2.1	Цели	2
2.2	Обзор Архитектуры	2
2.3	Ключевые Технологии	3
3	Технические Спецификации	4
3.1	Компонент Сбора Данных	4
3.1.1	Функциональность	4
3.1.2	Технические Детали	4
3.2	Компонент Предобработки Текста	4
3.2.1	Функциональность	4
3.2.2	Технические Детали	4
3.2.3	Конвейер Обработки	5
3.3	Компонент Извлечения Концепций	5
3.3.1	Функциональность	5
3.3.2	Технические Детали	5
3.4	Компонент Оценки Релевантности	6
3.4.1	Функциональность	6
3.4.2	Технические Детали	6
3.4.3	Категории Релевантности	6
3.5	Компонент Индексации	7
3.5.1	Функциональность	7
3.5.2	Технические Детали	7
3.5.3	Структура Индекса	7
3.6	Компонент Поиска и Извлечения	8
3.6.1	Функциональность	8
3.6.2	Технические Детали	8
3.6.3	Конвейер Обработки Запросов	8
3.7	Компонент Интеграции	8
3.7.1	Функциональность	8
3.7.2	Технические Детали	9
3.7.3	Спецификации API	9
4	План Реализации	10
5	Технические Требования	10
5.1	Требования к Производительности	10
6	Заключение	11
A	Глоссарий	11

1 Краткое Изложение

Индексатор содержания видеолекций — это система, предназначенная для обработки множества видеолекций с YouTube по различным академическим дисциплинам, создающая единый поисковый индекс концепций. Система позволяет студентам быстро находить соответствующий образовательный контент в большой базе видео, различая мимолётные упоминания и содержательное освещение концепций.

Основным техническим новшеством системы является применение алгоритмов линейного поиска множественной наибольшей общей подпоследовательности (MLCS) в сочетании с методами обработки естественного языка для идентификации, анализа и индексации академических концепций в транскриптах видео. Система будет интегрирована с параллельно разрабатываемой студенческой платформой, построенной на базе Java Spring с TypeScript/React фронтендом.

2 Обзор Системы

2.1 Цели

- Создание единого индекса академических концепций по нескольким видеолекциям
- Различение между мимолётными упоминаниями и содержательными объяснениями концепций
- Обеспечение эффективного поиска конкретных концепций с точными временными метками видео
- Поддержка автоматизированной обработки нового видеоконтента с минимальным ручным вмешательством
- Обеспечение бесшовной интеграции с существующей образовательной платформой

2.2 Обзор Архитектуры

Система следует модульной архитектуре со специализированными компонентами для каждой фазы конвейера обработки:




Рис. 1: Обзор архитектуры системы

2.3 Ключевые Технологии

- Языки программирования: C++ (основные алгоритмы), Python (обработка данных, NLP)
- Внешние API: YouTube Data API v3
- Библиотеки NLP: spaCy, NLTK
- База данных: PostgreSQL (прод), SQLite (разработка)
- Интеграция: REST API, обмен данными в формате JSON

3 Технические Спецификации

3.1 Компонент Сбора Данных

3.1.1 Функциональность

Компонент сбора данных отвечает за получение метаданных видео и транскриптов с YouTube.

3.1.2 Технические Детали

- Интеграция с YouTube API
 - Реализация Python-клиента для YouTube Data API v3
 - Поддержка как ручной, так и пакетной отправки видео
 - Обработка ограничений квоты API с дросселированием запросов
- Извлечение Транскрипта
 - Извлечение сегментов транскрипта с синхронизацией по времени
 - Поддержка нескольких языковых опций с приоритизацией
 - Обработка автоматически созданных субтитров с фильтрацией по уровню достоверности
- Обработка Метаданных
 - Извлечение заголовка видео, описания, тегов, продолжительности
 - Идентификация специфических метаданных лекции при их наличии
 - Хранение метаданных в структурированном формате, связанном с ID видео

3.2 Компонент Предобработки Текста

3.2.1 Функциональность

Компонент предобработки текста нормализует и улучшает текст транскрипта для дальнейшего анализа.

3.2.2 Технические Детали

- Нормализация Текста
 - Очистка и нормализация текста транскрипта
 - Сегментация текста на предложения
 - Сохранение синхронизации с временными метками
- Лингвистический Анализ
 - Выполнение частеречной разметки

- Применение лемматизации с сохранением исходного текста
- Идентификация академических дискурсивных маркеров
- Структурный Анализ
 - Обнаружение структуры лекции (введение, основное содержание, заключение)
 - Определение границ разделов на основе дискурсивных маркеров
 - Создание структурного слоя метаданных

3.2.3 Конвейер Обработки

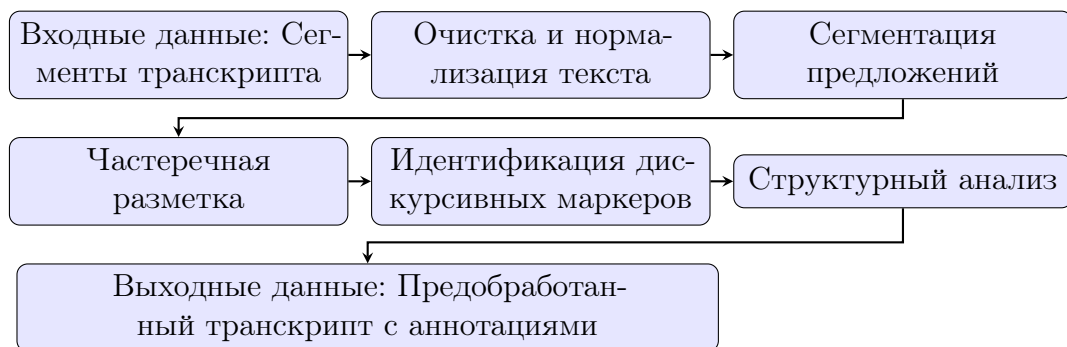


Рис. 2: Конвейер предобработки текста

3.3 Компонент Извлечения Концепций

3.3.1 Функциональность

Компонент извлечения концепций идентифицирует академические концепции в предобработанных транскриптах.

3.3.2 Технические Детали

- Идентификация Концепций по Предметным Областям
 - Реализация пользовательского распознавания именованных сущностей для академических областей
 - Применение TF-IDF и TextRank для извлечения терминологии
 - Обнаружение многословных академических концепций
- Алгоритм Linear MLCS
 - Реализация оптимизированной версии линейного MLCS на C++
 - Определение общих последовательностей концепций в разных лекциях
 - Обнаружение зависимостей концепций и предварительных условий
- Контекстный Анализ
 - Извлечение контекста, окружающего каждую концепцию

- Анализ лингвистических паттернов, указывающих на объяснение
- Измерение стабильности концепции в контексте

3.4 Компонент Оценки Релевантности

3.4.1 Функциональность

Компонент оценки релевантности определяет глубину освещения для каждого вхождения концепции.

3.4.2 Технические Детали

- Анализ Глубины Освещения
 - Реализация анализа скользящего окна
 - Расчет плотности концепции в локальном контексте
 - Измерение устойчивого внимания к концепциям
- Оценка Академической Значимости
 - Анализ паттернов акцентирования внимания преподавателем
 - Обнаружение педагогических структур
 - Измерение центральности в структуре лекции
- Расчет Композитной Релевантности
 - Объединение нескольких факторов оценки
 - Применение нормализации по всему корпусу видео
 - Классификация вхождений по категориям релевантности

3.4.3 Категории Релевантности

Категория	Диапазон Оценки	Описание
Содержательное Освещение	70-100	Подробное объяснение с определениями, примерами и применениями
Умеренное Освещение	40-69	Предоставляется некоторое объяснение, но не исчерпывающее
Краткое Упоминание	10-39	Концепция упоминается с минимальным контекстом
Мимолетное Упоминание	0-9	Концепция упоминается без объяснения

Таблица 1: Категории оценки релевантности

3.5 Компонент Индексации

3.5.1 Функциональность

Компонент индексации создает эффективный поисковый индекс концепций по всем видео.

3.5.2 Технические Детали

- Построение Инвертированного Индекса
 - Реализация оптимизированного инвертированного индекса на C++
 - Создание списков вхождений с временными метками и релевантностью
 - Применение сжатия для эффективного хранения
- Сохранение Индекса
 - Реализация сериализации/десериализации
 - Поддержка дифференциальных обновлений для нового контента
 - Обеспечение потокобезопасного параллельного доступа
- Интеграция Графа Знаний
 - Преобразование взаимосвязей концепций в структуру графа
 - Реализация возможностей навигации по концепциям
 - Поддержка семантических запросов отношений

3.5.3 Структура Индекса

```
1 ConceptIndex {
2   "concept_id": {
3     "canonical_name": "weierstrass theorem",
4     "variants": ["weierstrass theorem", "extreme value theorem"],
5     "concept_type": "theorem",
6     "domain": "mathematical_analysis",
7     "occurrence_count": 42,
8     "postings": [
9       {
10        "video_id": "abc123",
11        "relevance_score": 89,
12        "coverage_type": "substantive",
13        "timestamp_start": 1250.5,
14        "timestamp_end": 1380.2,
15        "segment_id": "abc123_seg42"
16      },
17      // More occurrences...
18    ]
19  },
20  // More concepts...
21 }
```

Листинг 1: Структура инвертированного индекса

3.6 Компонент Поиска и Извлечения

3.6.1 Функциональность

Компонент поиска и извлечения обрабатывает пользовательские запросы и возвращает релевантные сегменты видео.

3.6.2 Технические Детали

- Обработка Запросов
 - Реализация нормализации и расширения запросов
 - Преобразование естественного языка в структурированные запросы
 - Поддержка запросов взаимосвязей концепций
- Поиск по Индексу
 - Оптимизация операций булева поиска
 - Реализация близостного поиска для запросов с несколькими концепциями
 - Применение фильтрации по релевантности
- Ранжирование Результатов
 - Применение сложного алгоритма ранжирования
 - Извлечение точных сегментов видео
 - Генерация фрагментов результатов

3.6.3 Конвейер Обработки Запросов




Рис. 3: Конвейер обработки запросов

3.7 Компонент Интеграции

3.7.1 Функциональность

Компонент интеграции предоставляет API для подключения к существующей платформе.

3.7.2 Технические Детали

- Конечные Точки REST API
 - Реализация конечной точки отправки видео
 - Создание интерфейса поисковых запросов
 - Предоставление возможностей мониторинга статуса
- Асинхронная Обработка
 - Реализация управления очередью обработки
 - Предоставление обновлений статуса в реальном времени
 - Обработка восстановления после сбоев
- Интеграция с Фронтом
 - Определение структурированного формата ответов
 - Поддержка расширенных параметров запроса
 - Реализация стратегии кэширования на стороне клиента

3.7.3 Спецификации API

```
1 {
2   "query": "Weierstrass theorem",
3   "total_results": 24,
4   "results": [
5     {
6       "video_id": "abcd1234",
7       "title": "Advanced Calculus - Lecture 5",
8       "concept": "Weierstrass theorem",
9       "relevance_score": 89,
10      "coverage_type": "substantive",
11      "timestamp_start": 1250.5,
12      "timestamp_end": 1380.2,
13      "context_snippet": "Today we're going to prove the Weierstrass theorem which states that..."
14    },
15    "thumbnail_url": "https://...",
16    "related_concepts": ["uniform convergence", "continuous functions"]
17  },
18  // More results ...
19 }
```

Листинг 2: Формат ответа поискового API

4 План Реализации

Фаза	Продолжительность	Результаты
1. Базовая Инфраструктура	неделя 1	• Интеграция с YouTube API • Конвейер извлечения транскриптов • Реализация алгоритма MLCS на C++
2. Анализ Контента	неделя 2	• Конвейер предобработки NLP • Система извлечения концепций • Реализация контекстного анализа
3. Система Индексации	недели 3-4	• Реализация инвертированного индекса • Алгоритмы оценки релевантности • Слой сохранения индекса
4. Поисковая Система	недели 5-6	• Реализация обработки запросов • Алгоритм ранжирования результатов • Конечные точки поискового API • Реализация демонстративного консольного интерфейса
5. Интеграция	в будущем	• Интеграция с бэкендом Spring • Компоненты фронтенда React • Система асинхронной обработки
6. Тестирование & Оптимизация	в будущем	• Тестирование производительности • Настройка релевантности • Исправление ошибок и оптимизация

Таблица 2: Фазы разработки

5 Технические Требования

5.1 Требования к Производительности

- Эффективность Обработки
 - Обработка часовой видеолекции < 5 минут
 - Поддержка пакетной обработки нескольких видео

- Максимальное использование ОЗУ < 4 ГБ
- Производительность Поиска
 - Время отклика запроса < 200 мс для 95% запросов
 - Поддержка не менее 50 одновременных пользователей
 - Размер индекса растет сублинейно с объемом контента
- Качество Релевантности
 - Точность > 0.8 для классификации содержательного освещения
 - Полнота > 0.9 для идентификации концепций

6 Заключение

Разработанный "Индексатор содержания видеолекций" позволит студентам быстро находить нужные концепции в массиве видеоматериалов, четко различая случайные упоминания и полноценные объяснения тем.

В основе системы лежит применение алгоритма Linear MLCS в сочетании с методами обработки естественного языка. Модульная структура проекта обеспечивает его последовательную реализацию с четкими промежуточными результатами. Использование C++ для высокопроизводительных компонентов и Python для обработки данных создает оптимальный баланс между быстродействием и гибкостью разработки.

По завершении проект интегрируется с параллельно разрабатываемой студенческой платформой, существенно расширяя её функциональность за счет интеллектуального поиска по видеоконтенту.

А Глоссарий

- Linear MLCS (Множественная Наибольшая Общая Подпоследовательность) - Алгоритм для нахождения наибольшей общей подпоследовательности в нескольких последовательностях.
- Инвертированный Индекс - Структура данных, отображающая контент (концепции) на их расположение (видео, временные метки).
- Глубина Освещения - Мера того, насколько тщательно объяснена или обсуждена концепция.
- Стабильность Концепции - То, как долго концепция остается в центре внимания обсуждения в видео.
- Дискурсивные Маркеры - Лингвистические сигналы, указывающие на объяснение, определение или ссылку.
- Распознавание Сущностей (NER) - Техника NLP для идентификации именованных сущностей в тексте.